

Ciência de Dados - Trabalho Final

Desafio de Análise de Dados: da Pergunta à Decisão

1 Apresentação e Objetivo

Este é o segundo (e último) trabalho prático da disciplina (TP2) final da disciplina de Ciência de Dados. Ao longo do semestre vocês estudaram os principais fundamentos de Ciência de Dados, ferramentas (Git e Python/Jupyter), estatística básica e aplicada, probabilidade e teste de hipóteses, Análise Exploratória de Dados, Big Data e pesquisa reprodutível. Este trabalho tem como objetivo a aplicação do conhecimento adquirido durante o semestre na investigação de um problema real, como ocorre com um cientista de dados fora da sala de aula: com uma pergunta que alguém de verdade precisa responder, dados imperfeitos, e uma decisão no final.

Cada dupla poderá escolher um **tema diferente**, dentre os 13 propostos, na Seção 6. Isso significa que, ao final, serão produzidas investigações distintas sobre saúde, economia, esporte, meio ambiente, segurança, educação e outros domínios — não cópias do mesmo exercício.

O que este trabalho avalia, na prática

Não é “rodar um notebook até funcionar”. É: escolher a técnica certa para a pergunta certa, **justificar essa escolha**, executar com rigor, interpretar o resultado no contexto do problema (o que ele permite concluir e o que não permite), e comunicar isso com clareza para quem não acompanhou seu processo.

2 Formato do Trabalho

- **Duplas.** O trabalho é feito em duplas fixas. Se o número de alunos matriculados não for múltiplo de 2, uma dupla pode virar trio — mantendo os mesmos critérios de avaliação, com expectativa proporcionalmente maior de profundidade na análise.
- **Escolha dos temas.** Cada dupla poderá selecionar um tema dentre os disponíveis.

3 Requisitos Técnicos Mínimos

Todo trabalho, independentemente do tema, deve conter:

1. **Análise Exploratória de Dados (EDA)** completa: limpeza/tratamento do dado bruto, estatística descritiva, pelo menos três visualizações que respondam a perguntas específicas (não gráficos soltos).
2. **Pelo menos uma técnica formal** além da EDA, escolhida entre as vistas no curso e coerente com a pergunta do tema: teste de hipóteses, Teorema de Bayes, Big Data ou Aprendizado de Máquina (classificação, regressão ou agrupamento de dados). O tema sugere uma técnica natural, mas a dupla pode justificar uma escolha diferente.
3. **Reprodutibilidade:** repositório Git (GitHub ou GitLab) com histórico de commits real (não um único commit final), `README.md` explicando como rodar o projeto, e um arquivo de dependências (`requirements.txt` ou equivalente).
4. **Uma decisão ou recomendação final**, tecnicamente justificada, respondendo à pergunta central do tema — o trabalho não termina em “os dados mostram X”, termina em “portanto, a recomendação é Y, com esta ressalva Z”.

4 Entregáveis

1. **Repositório Git** público (ou privado com o professor convidado como colaborador) contendo o(s) notebook(s) Jupyter, os dados utilizados e o `README.md`.
2. **Relatório técnico escrito** (PDF, 10–15 páginas), estruturado como um artigo contendo: contexto do problema, pergunta central, dados e metodologia, resultados, limitações, conclusão (recomendação final) e referências. Para isso, utilizem o modelo da *Springer* no Overleaf ([Springer Nature Latex Template](#)).
3. **Apresentação em formato de seminário**, de 10 a 15 minutos por dupla. Trate os ouvintes como tomadores de decisão que não viram o código — a apresentação conta a história dos dados, não narra células de notebook.

Prazos

- Entrega do repositório e do relatório: **16/09/2026**, via Classroom.
- Apresentações (seminário): **17/09/2026** (manhã e tarde), ordem de acordo com o tema escolhido.

5 Critérios de Avaliação

A nota final do trabalho (NT) é composta por três eixos (compreensão teórica, aplicação prática, análise crítica e participação):

$$NT = 0,40 \times \text{Desenvolvimento} + 0,30 \times \text{Apresentação} + 0,30 \times \text{Entrega}$$

Eixo (peso)	Insuficiente	Adequado	Excelente
Desenvolvimento (40%) — rigor técnico, escolha e execução da(s) técnica(s), reprodutibilidade	Técnica aplicada não corresponde à pergunta, ou código não roda, ou não há Git com histórico real	Técnica correta, código funciona, EDA completa, repositório organizado, mas pouca discussão de limitações	Técnica bem justificada tecnicamente, código limpo e comentado, EDA rica, limitações e alternativas discutidas com profundidade
Apresentação (30%) — seminário, clareza, domínio, resposta a perguntas	Leitura de slides/código, sem narrativa, dupla não responde perguntas com segurança	Narrativa clara do problema à conclusão, domínio razoável, responde à maioria das perguntas	Comunicação de dados no nível de <i>storytelling</i> (gráficos pensados para a plateia, não para o notebook), domínio total do próprio trabalho, respostas seguras e honestas sobre limitações
Entrega (30%) — relatório escrito, organização, conclusões	Relatório incompleto, sem fonte de dados declarada, sem recomendação final clara	Relatório completo, fonte de dados declarada, recomendação final presente mas pouco fundamentada	Relatório bem escrito e organizado, recomendação final tecnicamente fundamentada, limitações e riscos da decisão explicitados

6 Temas Sugeridos

A seguir são apresentados os temas que as duplas podem escolher. Cada um indica: o contexto, a pergunta central que orienta a investigação, uma sugestão de fonte de dados e as técnicas mais

“naturais” do curso para investigar o problema — a dupla tem liberdade para ajustar a pergunta ou a técnica, justificando a mudança no relatório.

Tema 1 — Cobertura vacinal e mortalidade infantil por região

Contexto: municípios brasileiros investem de forma desigual em campanhas de vacinação infantil. **Pergunta central:** existe relação entre cobertura vacinal e indicadores de mortalidade infantil entre regiões? **Dados:** DataSUS/OpenDataSUS, indicadores por município/estado. **Técnicas:** EDA, correlação, teste de hipóteses comparando regiões.

Tema 2 — Desempenho no ENEM por perfil socioeconômico

Contexto: o ENEM é usado para acesso ao ensino superior público. **Pergunta central:** o desempenho médio varia de forma relevante conforme renda familiar e tipo de escola (pública/privada)? **Dados:** microdados do ENEM (INEP). **Técnicas:** EDA, estatística descritiva por grupo, teste de hipóteses.

Tema 3 — Mercado de trabalho: escolaridade e remuneração

Contexto: decisões de política pública de qualificação profissional dependem de entender o retorno da escolaridade. **Pergunta central:** qual o ganho salarial médio associado a cada nível de escolaridade, e isso varia por setor? **Dados:** PNAD Contínua (IBGE) ou RAIS. **Técnicas:** EDA, correlação, regressão simples.

Tema 4 — Mudança climática: temperatura e chuva ao longo dos anos

Contexto: uma prefeitura quer entender se o padrão climático da região está mudando, para planejar infraestrutura. **Pergunta central:** há tendência estatisticamente relevante de aumento de temperatura ou mudança no padrão de chuvas na série histórica? **Dados:** estações do INMET. **Técnicas:** EDA temporal, teste de hipóteses, visualização de séries.

Tema 5 — Acidentes de trânsito em rodovias

Contexto: um órgão de trânsito quer priorizar trechos de rodovia para fiscalização. **Pergunta central:** em quais condições (horário, clima, tipo de via) os acidentes graves se concentram? **Dados:** DATATRAN/PRF. **Técnicas:** EDA, segmentação de ocorrências, classificação de gravidade (KNN).

Tema 6 — Criminalidade urbana por região

Contexto: uma secretaria de segurança quer redistribuir policiamento entre bairros. **Pergunta central:** os tipos de ocorrência têm padrão espacial ou temporal (dia da semana, horário) identificável? **Dados:** painéis abertos de secretarias estaduais de segurança pública. **Técnicas:** EDA, sazonalidade, segmentação por região.

Tema 7 — Inflação de alimentos e poder de compra

Contexto: o preço de itens básicos pressiona o orçamento familiar de forma desigual entre categorias. **Pergunta central:** quais categorias de alimentos mais pressionaram a inflação no período analisado, e isso é sazonal? **Dados:** IPCA (IBGE) ou séries do Banco Central (SGS). **Técnicas:** EDA temporal, comparação entre categorias, teste de hipóteses.

Tema 8 — Desempenho de times no Campeonato Brasileiro

Contexto: um clube quer entender que fatores (mandante/visitante, gols marcados/sufridos) mais se associam a vitórias. **Pergunta central:** jogar em casa realmente muda a probabilidade de vitória, e por quanto? **Dados:** bases públicas de resultados do Brasileirão (ex.: Kaggle). **Técnicas:** EDA, teste de hipóteses, classificação do resultado (KNN).

Tema 9 — Popularidade de filmes e séries em plataformas de streaming

Contexto: uma plataforma quer entender o que caracteriza um título bem avaliado. **Pergunta central:** gênero, duração e ano de lançamento se relacionam com a nota média do público? **Dados:** bases públicas tipo IMDB/Netflix (ex.: Kaggle). **Técnicas:** EDA, correlação, segmentação por gênero.

Tema 10 — Produtividade agrícola por safra e região

Contexto: uma cooperativa quer prever tendências de safra para planejar estoque. **Pergunta central:** a produtividade por hectare varia mais entre regiões ou entre anos (clima)? **Dados:** levantamentos da CONAB. **Técnicas:** EDA temporal e espacial, teste de hipóteses.

Tema 11 — Sazonalidade do consumo residencial de energia elétrica

Contexto: uma instituição de planejamento energético quer compreender como o consumo residencial varia ao longo do ano e entre diferentes regiões do Brasil, apoiando campanhas de eficiência energética. **Pergunta central:** o consumo residencial apresenta um padrão sazonal claramente identificável, e esse padrão varia entre estados ou regiões brasileiras? **Dados:** dados abertos da Empresa de Pesquisa Energética (EPE), com consumo mensal e número de consumidores da classe residencial, agregados por unidade da Federação e região geográfica desde 2004. **Técnicas:** EDA temporal, análise de sazonalidade, comparação ou teste de hipóteses entre regiões e, opcionalmente, segmentação das unidades da Federação por perfil de consumo.

Tema 12 — Demanda no transporte público de Salvador

Contexto: a gestão do transporte público precisa adequar a oferta de veículos às variações espaciais e temporais da demanda. **Pergunta central:** como a demanda varia por horário, dia da semana, linha e modalidade, e quais linhas ou estações deveriam ser priorizadas em um eventual ajuste da oferta? **Dados:** Salvador Urban Network Transportation (SUNT), contendo dados de ônibus, BRT e metrô de Salvador. A análise deverá utilizar um recorte reproduzível do conjunto de dados processado. **Técnicas:** EDA temporal e espacial, análise de sazonalidade e teste de hipóteses comparando horários, dias, linhas ou modalidades; opcionalmente, segmentação de linhas ou estações por perfil de demanda.

Tema 13 — Catálogo de exoplanetas

Contexto: astrônomos catalogam milhares de exoplanetas descobertos por diferentes métodos. **Pergunta central:** o método de detecção (trânsito, velocidade radial etc.) se associa a características diferentes de planeta (tamanho, distância da estrela)? **Dados:** NASA Exoplanet Archive (catálogo público). **Técnicas:** EDA, comparação entre grupos, teste de hipóteses.

7 Diretrizes de Dados e Ética

- Os dados utilizados devem ter a fonte citada de forma completa (organização, link de acesso e data de download) no relatório e no `README.md` do repositório.
- Nenhum trabalho deve usar dados pessoais sensíveis e identificáveis (nomes de pessoas, CPF, dados de saúde individualizados) sem anonimização — prefira bases públicas já anonimizadas ou agregadas.
- Créditos: se o código ou a estrutura de análise foi inspirado em algum material do curso, do professor, ou de terceiros, isso deve ser citado no relatório — é o mesmo princípio de honestidade acadêmica da aula de Pesquisa Reprodutível.

Dúvidas sobre o tema ou sobre acesso aos dados devem ser levadas à próxima aula ou ao horário de atendimento — quanto antes, melhor, para não comprometer o prazo de entrega.